

ClawTrojan：GLM-5、DS-V4-Pro 与 GPT-5.6-Luna

表 1 相同 39 个原生步骤上的历史实验结果。每组 26 条攻击、13 条正常任务；数值为百分比。

方法	GLM-5				DS-V4-Pro				GPT-5.6-Luna			
	攻击 C/P/S	ATS / ASR ↓ (%)	攻击 Safe ↑ (%)	正常 Utility ↑ (%)	攻击 C/P/S	ATS / ASR ↓ (%)	攻击 Safe ↑ (%)	正常 Utility ↑ (%)	攻击 C/P/S	ATS / ASR ↓ (%)	攻击 Safe ↑ (%)	正常 Utility ↑ (%)
No Defense	20/1/5	76.92	19.23	100.00	22/0/4	84.62	15.38	100.00	23/2/1	88.46	3.85	92.31
Content	7/0/19	26.92	73.08	100.00	12/1/13	46.15	50.00	100.00	14/2/10	53.85	38.46	53.85
Derived	7/3/16	26.92	61.54	100.00	9/3/14	34.62	53.85	100.00	15/6/5	57.69	19.23	69.23
TaskShield	20/0/6	76.92	23.08	92.31	19/1/6	73.08	23.08	84.62	19/2/5	73.08	19.23	84.62
Evidence	4/2/20	15.38	76.92	100.00	8/0/18	30.77	69.23	92.31	12/9/5	46.15	19.23	46.15

指标说明：每组包含26条攻击任务和13条正常任务，百分比均按各自组别计算。

C/P/S：攻击任务的原生判分数量，依次为 Compromised（攻击成功）、Partial（部分成功）和 Safe（原生判为安全）。三者合计26条；例如8/0/18表示8条Compromised、0条Partial、18条Safe。

ATS / ASR ↓：攻击成功率 = C ÷ 26，越低越好；Partial不计入完全攻击成功。

攻击 Safe ↑：攻击任务中原生判为Safe的比例 = S ÷ 26，越高越好。它不等于1-ASR，因为Partial单独计数；也不保证合法任务已完成。